Checkpoint 3 - Aprendizado Profundo com Redes Neurais Convolucionais

Professor:

- Fernando Nascimento da Silva

Integrante:

• Leonardo Lopes Oliveira RM - 565437

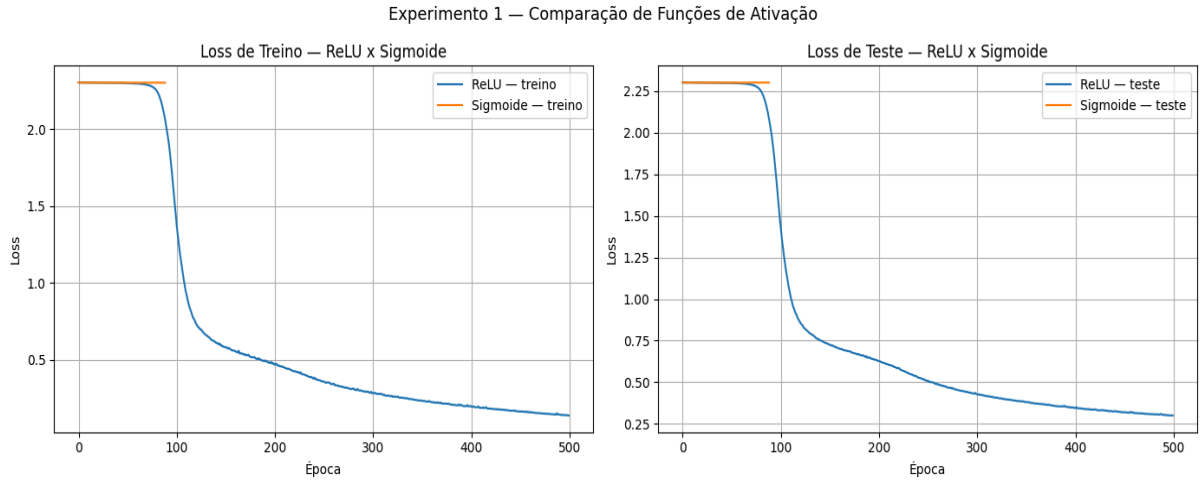
Curso: Ciências da Computação

Turma: 2CCPW

Experimento 1: ReLU x Sigmoide

Configurações testadas: 2 camadas ocultas, 128 neurônios na primeira camada e 64 na segunda, learning rate de 0,005, batch size de 128, máximo de 500 épocas e early stopping com patience de 50. Base de dados: MNIST reduzida.

Loss de Treino e Teste — ReLU x Sigmoide:



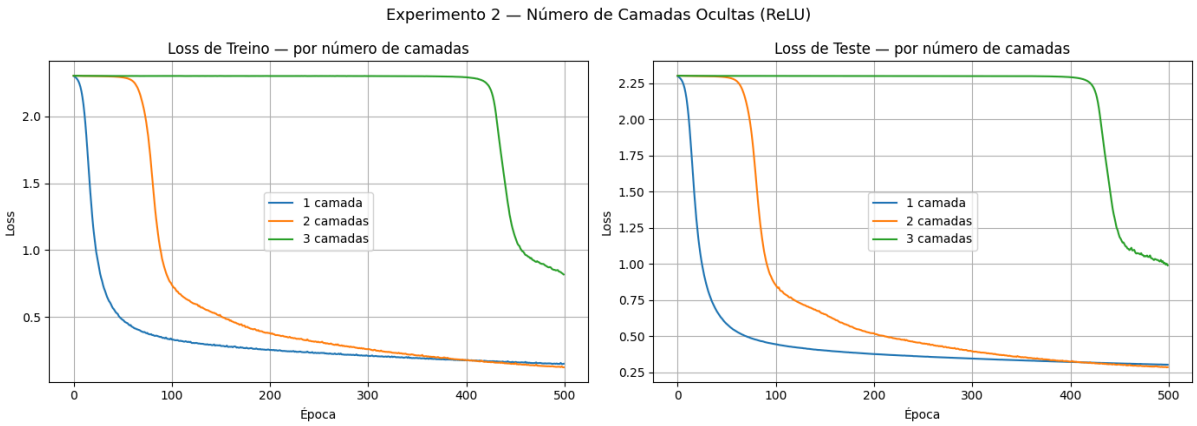
Resultados: ReLU — Acurácia treino: 96.34% | Acurácia teste: 90.50%. Sigmoide — Acurácia treino: 11.27% | Acurácia teste: 11.70%

Conclusão: A função ReLU convergiu com sucesso, reduzindo o loss consistentemente ao longo das épocas. A Sigmoide falhou completamente em aprender nesta configuração: a curva de Loss permaneceu estagnada em ~2,30 durante todo o treinamento, o que indica colapso do gradiente nas camadas ocultas. Esse comportamento é esperado quando pesos são inicializados com valores muito pequenos (0,01) combinados com Sigmoide, cujas derivadas próximas de zero sufocam o sinal de gradiente durante o backpropagation. ReLU não sofre desse problema nas mesmas condições.

Experimento 2 — Comparação: 1, 2 e 3 Camadas Ocultas (Ativação: ReLU)

Configurações testadas: todas com ReLU, learning rate de 0,005 e batch size de 128. 1 camada oculta: arquitetura [784, 128, 10], patience 50. 2 camadas ocultas: arquitetura [784, 128, 128, 10], patience 50. 3 camadas ocultas: arquitetura [784, 128, 128, 128, 10], patience 100.

Loss de Treino e Teste — por número de camadas:



Resultados: 1 camada — Acurácia treino: 95.85% | Acurácia teste: 90.45%. 2 camadas — Acurácia treino: 96.77% | Acurácia teste: 91.35%. 3 camadas — Acurácia treino: 74.46% | Acurácia teste: 68.40%

Melhor acurácia obtida na base de teste: 91.35%

Conclusão: Redes mais profundas demoraram significativamente mais para convergir com gradiente descendente puro. A rede de 3 camadas ainda não havia convergido ao atingir o limite de épocas, evidenciando que profundidade sem técnicas de otimização mais avançadas (como Adam ou batch normalization) pode prejudicar o treinamento. As redes de 1 e 2 camadas apresentaram desempenho similar em termos de loss final,

sugerindo que para o MNIST com base reduzida do MNIST, capacidade adicional nem sempre se traduz em ganho imediato.